

# Youtube推荐系统论文

论文[pje]是工程界关于深度学习推荐系统比较典型的论文。

## 目标

1. Scale: Highly specialized distributed learning algorithms and efficient serving systems
2. Freshness: balancing new contents with well-formed videos
3. Noise: robust to particular characteristics of training data

## Overview

2层神经网络，第一层产生候选（粗排），一层用来生成排序（精排）。

## 候选生成

### 问题建模

生成阶段转换为多分类(**Efficient Extreme Multiclass**)问题。即在时刻t，为用户U（上下文信息C）在视频库V中精准的预测出视频i的类别（每个具体的视频视为一个类别，i即为一个类别）。

$$P(w_t = i|U, C) = \frac{e^{v_i u}}{\sum_{j \in V} e^{v_j u}}$$

该模型需要利用embedding来表示用户历史和视频信息，难点在于如何高效的处理海量的分类，参考了word2vec有2种方案：1) [negative sampling](#)；2) [hierarchical softmax](#)。论文采用了方案1) 是因为考虑到2) 方案要求类别簇节点之间是无关的，很难在推荐场景试用，同时方案1) 实现更简单。

### 模型架构

模型采用(watch video, search tokens, geographic embedding, example age, gender, ...) 等多种维度特征进行forward反馈获得user embedding。对于计算candidate videos，训练阶段试用negative sampling替换softmax来加速，serving阶段使用softmax来获得video embedding跟user embedding计算点积，选择topK作为最终推荐的视频。

example age没有明确定义，简单理解为视频上传之后曝光的时间。gender等属于用户个体特征。

文中还提到了一些label和context选择的技巧。特别是asymmetric co-watch，采用序列式的方式预测next watch，效果比传统的协同过滤更好。

## RANKING

由于经过候选生成阶段的筛选，视频候选只有几百量级，所以候选排序阶段可以引入更多特征进行精细的打分排序。

排序阶段采用和候选生成阶段类似的网络结构，用logistics regresion对视频进行打分。不同的是，排序阶段采用观看时长作为学习目标而非点击率，因为点击率会有很多诱导点击的标题党内容，用户点击后很快会停止观看，所以观看时长是一个更合适表示用户是否感兴趣的指标。

## 模型

可以看到，ranking阶段 training的最后一层是[weighted LR](#)，来体现期望时长在排序中影响(对数几率odds)，serving用的激活函数是exp，其次是特征工程跟候选阶段不一样。

## 特征工程

图7中，从左至右的特征依次是：

1. **impression video ID embedding**: 当前要计算的video的embedding;
2. **watched video IDs average embedding**: 用户观看过的最后N个视频embedding的average pooling;
3. **language embedding**: 用户语言的embedding和当前视频语言的embedding;
4. **time since last watch**: 自上次观看同channel视频的时间，类似[“attention”](#)，根据注意力范围生成下一个video的权重;
5. **#previous impressions**: 该视频已经被曝光给该用户的次数, 上一次推荐后，用户没有点击，那么下一次就应该更换;

从这篇论文基本了解了一个典型的基于深度学习的推荐系统架构。

## 参考

---

[PJE] Paul Covington, Jay Adams, Emre Sargin Google, [Deep Neural Networks for YouTube Recommendations](#), <https://zhuanlan.zhihu.com/p/52169807>