

Youtube推荐系统论文

论文[pje]是工程界关于深度学习推荐系统比较典型的论文。

目标

1. Scale: Highly specialized distributed learning algorithms and efficient serving systems
2. Freshness: balancing new contents with well-formed videos
3. Noise: robust to particular characteristics of training data

Overview

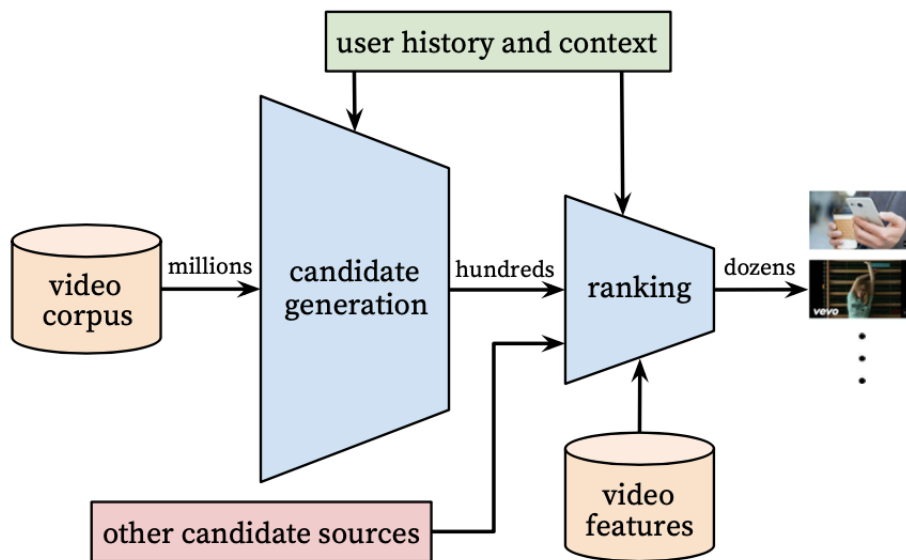


Figure 2: Recommendation system architecture demonstrating the “funnel” where candidate videos are retrieved and ranked before presenting only a few to the user.

2层神经网络，第一层产生候选（粗排），一层用来生成排序（精排）。

候选生成

问题建模

生成阶段转换为多分类(**Efficient Extreme Multiclass**)问题。即在时刻 t ，为用户 U （上下文信息 C ）在视频库 V 中精准的预测出视频 i 的类别（每个具体的视频视为一个类别， i 即为一个类别）。

$$P(w_t = i | U, C) = \frac{e^{v_i u}}{\sum_{j \in V} e^{v_j u}}$$

该模型需要利用embedding来表示用户历史和视频信息，难点在于如何高效的处理海量的分类，参考了word2vec有2种方案：1) [negative sampling](#)；2) [hierarchical softmax](#)。论文采用了方案1) 是因为考虑到2) 方案要求类别簇节点之间是无关的，很难在推荐场景试用，同时方案1) 实现更简单。

模型架构

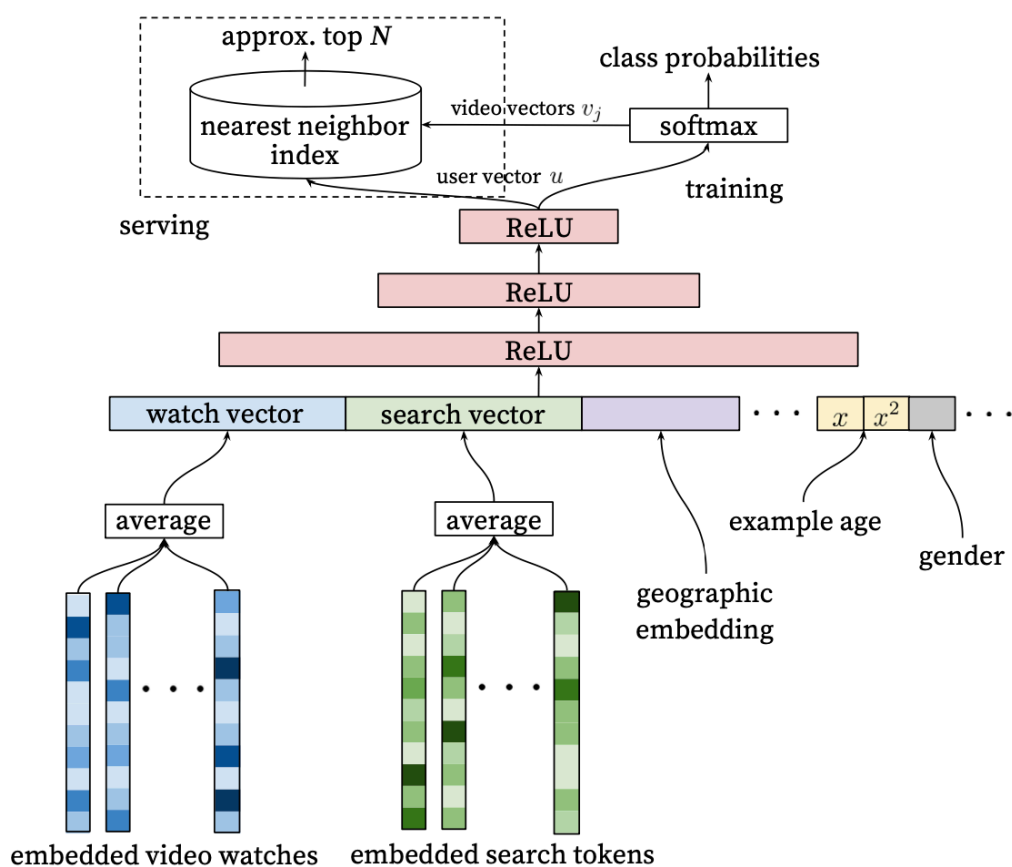


Figure 3: Deep candidate generation model architecture showing embedded sparse features concatenated with dense features. Embeddings are averaged before concatenation to transform variable sized bags of sparse IDs into fixed-width vectors suitable for input to the hidden layers. All hidden layers are fully connected. In training, a cross-entropy loss is minimized with gradient descent on the output of the sampled softmax. At serving, an approximate nearest neighbor lookup is performed to generate hundreds of candidate video recommendations.

模型采用(watch video, search tokens, geographic embedding, example age, gender, ...)等多种维度特征进行forward反馈获得user embedding。对于计算candidate videos，训练阶段试用negative sampling替换softmax来加速，serving阶段使用softmax来获得video embedding跟user embedding计算点积，选择topK作为最终推荐的视频。

example age没有明确定义，简单理解为视频上传之后曝光的时间。gender等属于用户个体特征。

文中还提到了一些label和context选择的技巧。特别是asymmetric co-watch，采用序列式的方式预测next watch，效果比传统的协同过滤更好。

RANKING

由于经过候选生成阶段的筛选，视频候选只有几百量级，所以候选排序阶段可以引入更多特征进行精细的打分排序。

排序阶段采用和候选生成阶段类似的网络结构，用logistics regression对视频进行打分。不同的是，排序阶段采用观看时长作为学习目标而非点击率，因为点击率会有很多诱导点击的标题党内容，用户点击后很快会停止观看，所以观看时长是一个更合适表示用户是否感兴趣的指标。

模型

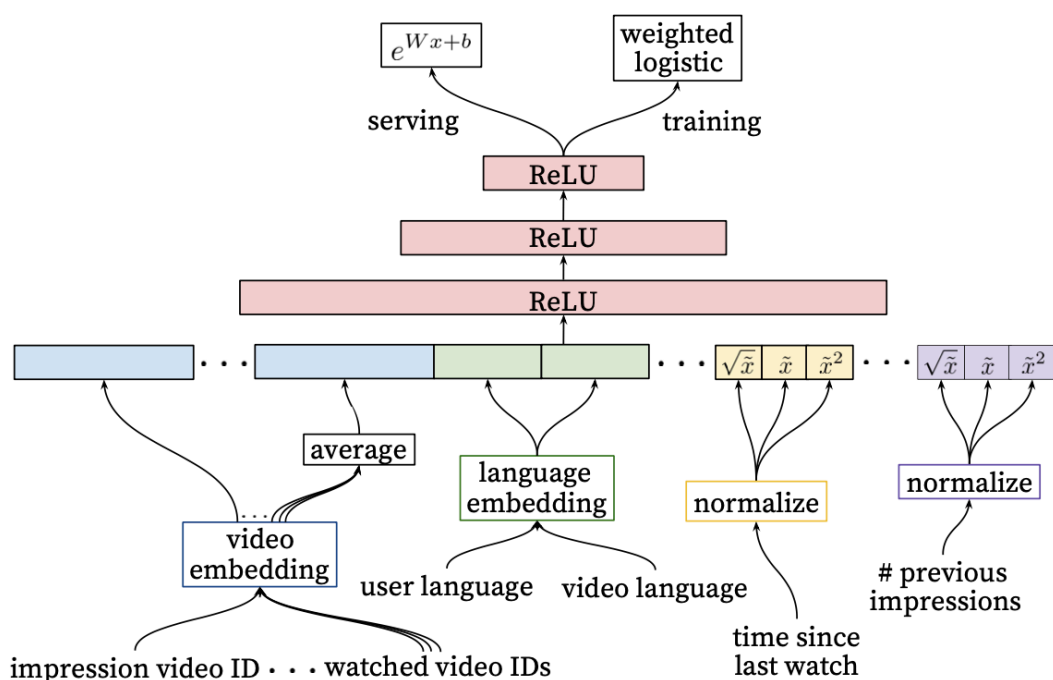


Figure 7: Deep ranking network architecture depicting embedded categorical features (both univalent and multivalent) with shared embeddings and powers of normalized continuous features. All layers are fully connected. In practice, hundreds of features are fed into the network.

可以看到，ranking阶段 training的最后一层是[weighted LR](#)，来体现期望时长在排序中影响(对数几率odds)，serving用的激活函数是exp，其次是特征工程跟候选阶段不一样。

特征工程

图7中，从左至右的特征依次是：

1. **impression video ID embedding**: 当前要计算的video的embedding;
2. **watched video IDs average embedding**: 用户观看过的最后N个视频embedding的average pooling;
3. **language embedding**: 用户语言的embedding和当前视频语言的embedding;
4. **time since last watch**: 自上次观看同channel视频的时间，类似[attention](#)，根据注意力范围生成下一个video的权重;
5. **#previous impressions**: 该视频已经被曝光给该用户的次数, 上一次推荐后，用户没有点击，那么下一次就应该更换;

从这篇论文基本了解了一个典型的基于深度学习的推荐系统架构。

参考

[PJE] Paul Covington, Jay Adams, Emre Sargin Google, [Deep Neural Networks for YouTube Recommendations](#), <https://zhuanlan.zhihu.com/p/52169807>