

Google推荐系统论文

Bing Duan, 2020.9

Google推荐系统论文

Deep Neural Networks for YouTube Recommendations

目标

Overview

候选生成

问题建模

模型架构

RANKING

模型

特征工程

Wide & Deep Learning for Recommender Systems

目标

网络模型

Deep操作

Wide & Deep联合训练

Model Serving

参考

Deep Neural Networks for YouTube Recommendations

本文提出了一种典型的推荐系统架构，将召回看做多分类问题，利用深度学习对用户和视频做embedding，然后通过计算用户和视频embedding之间的得分，排序阶段再次利用深度学习，结合多种特征进行精排。是工程实现的典范。

目标

1. Scale: Highly specialized distributed learning algorithms and efficient serving systems
2. Freshness: balancing new contents with well-formed videos
3. Noise: robust to particular characteristics of training data

Overview




Figure 2: Recommendation system architecture demonstrating the “funnel” where candidate videos are retrieved and ranked before presenting only a few to the user.

2层神经网络，第一层产生候选（粗排），一层用来生成排序（精排）。

候选生成

问题建模

生成阶段转换为多分类(**Efficient Extreme Multiclass**)问题。即在时刻 t ，为用户 U （上下文信息 C ）在视频库 V 中精准的预测出视频 i 的类别（每个具体的视频视为一个类别， i 即为一个类别）。

$$P(w_t = i|U, C) = \frac{e^{v_i u}}{\sum_{j \in V} e^{v_j u}}$$

该模型需要利用embedding来表示用户历史和视频信息，难点在于如何高效的处理海量的分类，参考了word2vec有2种方案：1) [negative sampling](#)；2) [hierarchical softmax](#)。论文采用了方案1) 是因为考虑到2) 方案要求类别簇节点之间是无关的，很难在推荐场景试用，同时方案1) 实现更简单。

模型架构

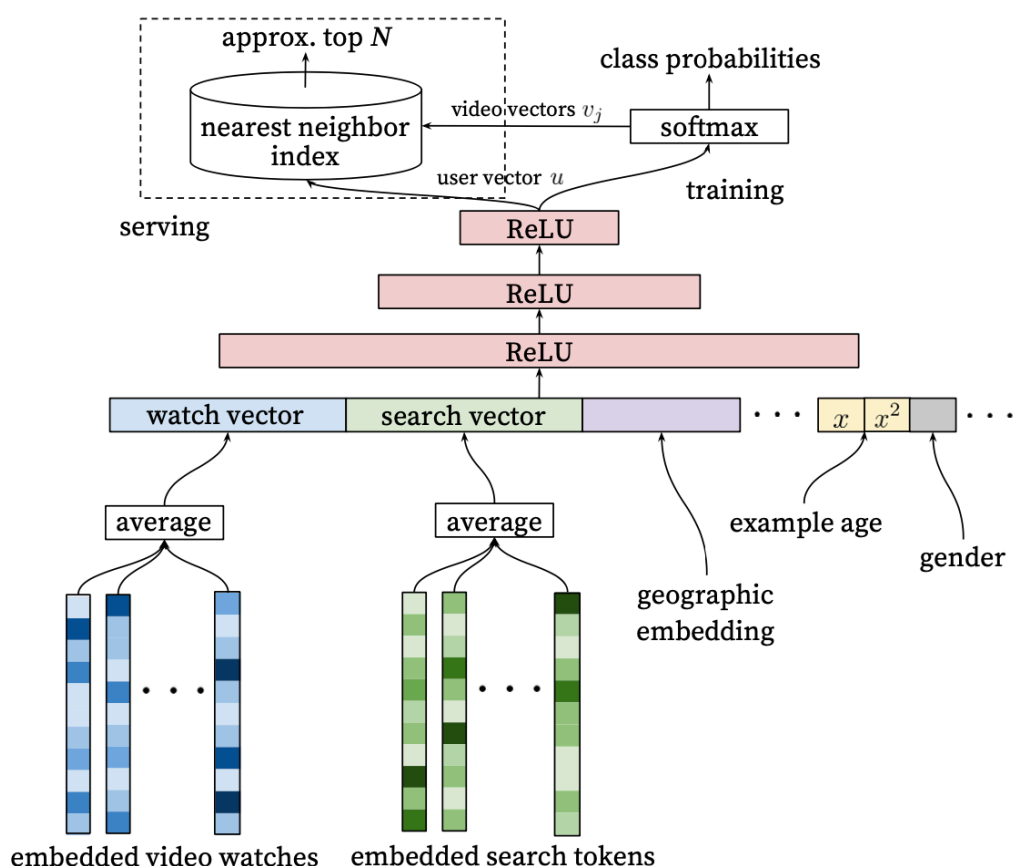


Figure 3: Deep candidate generation model architecture showing embedded sparse features concatenated with dense features. Embeddings are averaged before concatenation to transform variable sized bags of sparse IDs into fixed-width vectors suitable for input to the hidden layers. All hidden layers are fully connected. In training, a cross-entropy loss is minimized with gradient descent on the output of the sampled softmax. At serving, an approximate nearest neighbor lookup is performed to generate hundreds of candidate video recommendations.

模型采用(watch video, search tokens, geographic embedding, example age, gender, ...)等多种维度特征进行forward反馈获得user embedding。对于计算candidate videos，训练阶段试用negative sampling替换softmax来加速，serving阶段使用softmax来获得video embedding跟user embedding计算点积，选择topK作为最终推荐的视频。

example age没有明确定义，简单理解为视频上传之后曝光的时间。gender等属于用户个体特征。

文中还提到了一些label和context选择的技巧。特别是asymmetric co-watch，采用序列式的方式预测next watch，效果比传统的协同过滤更好。

RANKING

由于经过候选生成阶段的筛选，视频候选只有几百量级，所以候选排序阶段可以引入更多特征进行精细的打分排序。

排序阶段采用和候选生成阶段类似的网络结构，用logistics regression对视频进行打分。不同的是，排序阶段采用观看时长作为学习目标而非点击率，因为点击率会有很多诱导点击的标题党内容，用户点击后很快会停止观看，所以观看时长是一个更合适表示用户是否感兴趣的指标。

模型




Figure 7: Deep ranking network architecture depicting embedded categorical features (both univalent and multivalent) with shared embeddings and powers of normalized continuous features. All layers are fully connected. In practice, hundreds of features are fed into the network.

可以看到，ranking阶段 training的最后一层是[weighted LR](#)，来体现期望时长在排序中影响(对数几率odds)，serving用的激活函数是exp，其次是特征工程跟候选阶段不一样。

特征工程

图7中，从左至右的特征依次是：

1. **impression video ID embedding**: 当前要计算的video的embedding;
2. **watched video IDs average embedding**: 用户观看过的最后N个视频embedding的average pooling;
3. **language embedding**: 用户语言的embedding和当前视频语言的embedding;
4. **time since last watch**: 自上次观看同channel视频的时间，类似[“attention”](#)，根据注意力范围生成下一个video的权重；
5. **#previous impressions**: 该视频已经被曝光给该用户的次数，上一次推荐后，用户没有点击，那么下一次就应该更换；

从这篇论文基本了解了一个典型的基于深度学习的推荐系统架构。

Wide & Deep Learning for Recommender Systems

Google在2016年提出的一个深度学习模型，应用于Google Play应用商店上的APP推荐，该模型经过在线AB测试获得了比较好的效果。

目标

将推荐系统看做query = user + context的检索系统，输出是物品推荐列表。考虑到当前线性模型(wide model)虽然简单，具备"记忆"能力，但是需要大量的人工特征工作，所以考虑将深度学习(Deep mode)跟线性模型结合，兼顾"记忆"和"泛华"能力。

网络模型




Figure 1: The spectrum of Wide & Deep models.

Wide操作

对于 $y = W^T x + b$, x 主要包含2类特征： 1) 原始输入特征； 2) 通过交叉积（cross-product）变换后的特征，变换定义如下：

$$\theta_k(x) = \prod_{i=1}^d x_i^{c_{ki}} \quad c_{ki} \in 0, 1$$

也就是当第k次转换所包含的成分特征 x_i 为1的时候（例如二元特征AND (gender = female, language=en), 必须2个条件都满足），交叉积才为1， $\theta_k(x)$ 为所有成分特征的乘积。

Deep操作

Deep部分是一个MLP。每个一个隐藏层的转换为： $\alpha^{(l+1)} = f(W_{deep}^{(l)} \alpha^{(l)} + b^{(l)})$, l 代表层数。 $f(*)$ 是激活函数，一般是ReLU。 W, b 是要训练的参数。

Wide & Deep联合训练

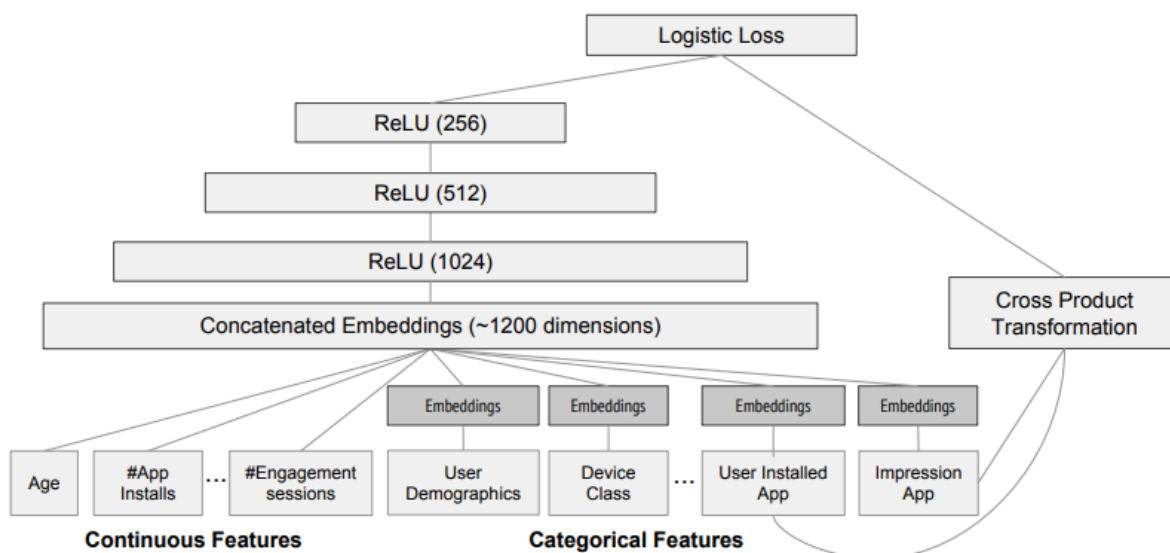


Figure 4: Wide & Deep model structure for apps recommendation.

如上图，训练过程将数值特征、类别特征等通过embedding处理，构成一个大概约1200维的向量灌入Deep模型，Wide模型则是使用APP安装和APP评分(impression)两类特征通过交叉积变换形成模型需要的特征。最后通过反向传播算法来训练该模型(wide模型采用FTRL优化器，deep模型采用AdaGrad优化器)，并上线到APP推荐业务中做AB测试。

Model Serving

基于用户特征和候选app信息，在Wide&Deep网络上运行前向计算，在预测部分，例如对于逻辑回归问题，采用如下模型进行计算：

$$P(Y = 1|x) = \sigma(w_{wide}^T [x, \theta(x)] + w_{deep}^T \alpha^{(l_f)} + b)$$

Y是二元分类标签， $\sigma(*)$ 表示sigmoid函数， $\theta(x)$ 是原始特征的交叉积， w_{wide} 是wide模型权重参数。

参考

[PJE] Paul Covington, Jay Adams, Emre Sargin Google, [Deep Neural Networks for YouTube Recommendations](https://zhuanlan.zhihu.com/p/52169807), <https://zhuanlan.zhihu.com/p/52169807>

[HLJ+] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, et.al Wide & Deep Learning for Recommender Systems